

# Atividade 4

Carlos Souza

```
ndvi <- read_excel("dados_ndvi_1985_2021.xlsx")
ndv1.1 <- ndvi

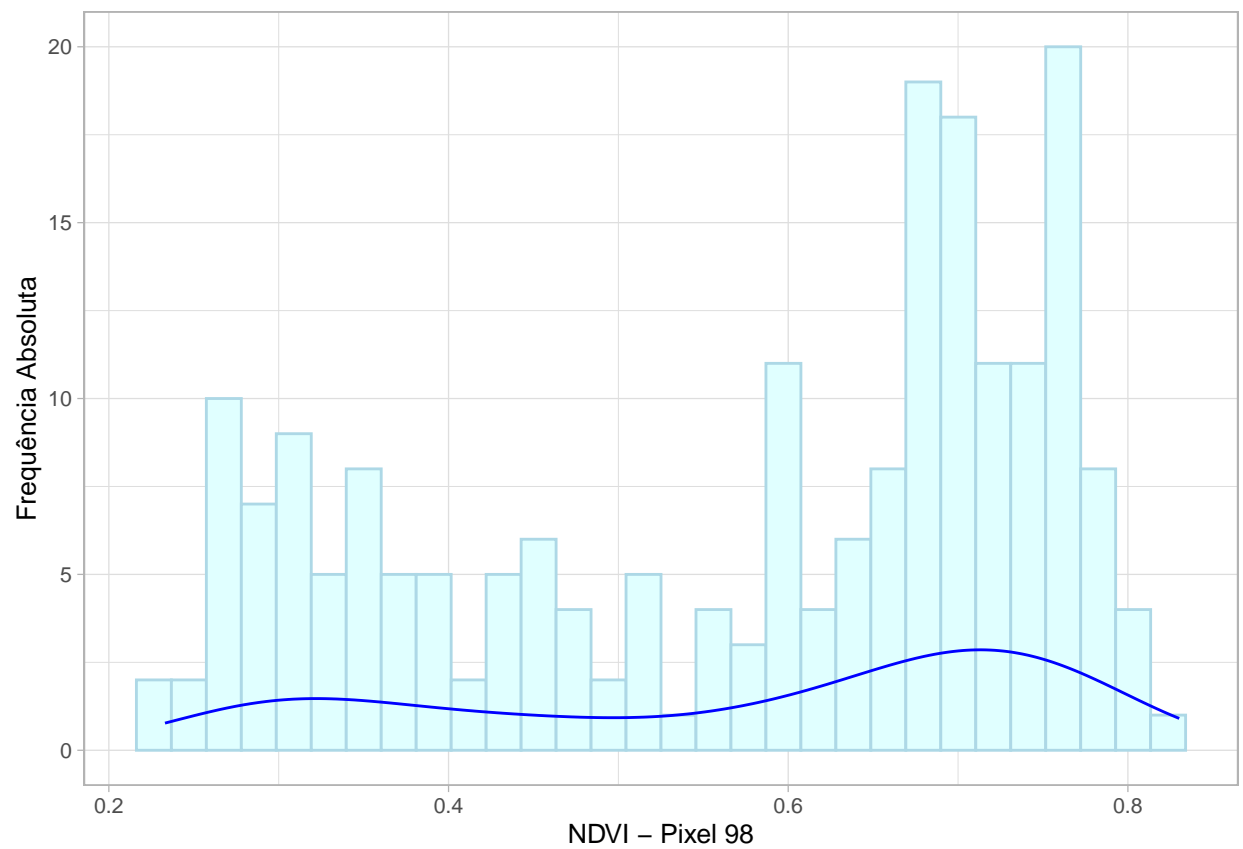
# Tratando os dados
ndvi$data=ymd(ndvi$data)
ndvi = ndvi%>%mutate(ano = year(data),
                    mes = month(data),
                    dia = day(data))

# Escolhendo um pixel
dados_2013_2021 <- ndvi %>% filter(pixel == "P98", data > "2013-01-01") %>%
  group_by(ano) %>% mutate(ordem_ano=factor(order(data)))
```

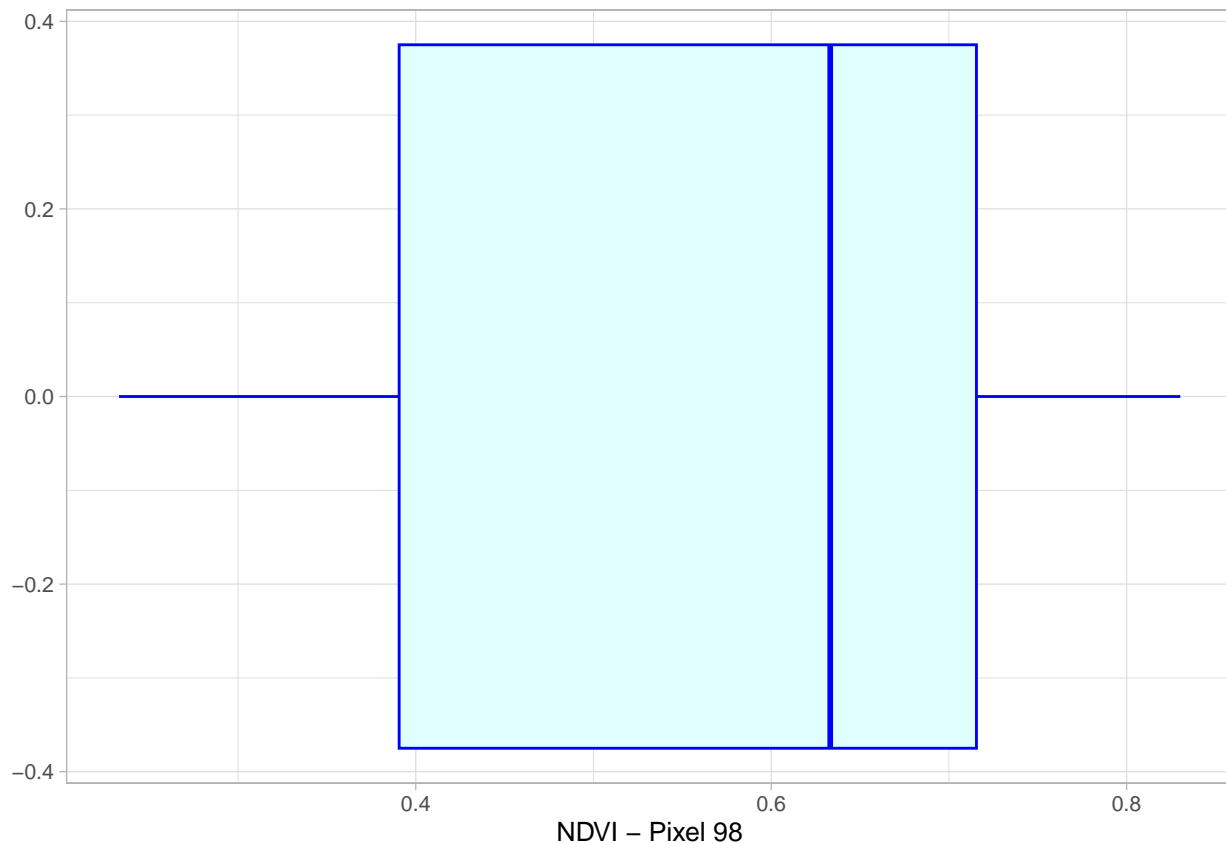
Questão 1

```
# Histograma
ggplot(data = dados_2013_2021, aes(x = ndvi)) +
  geom_histogram(color="lightblue", fill="lightcyan") +
  geom_density(col = "blue") +
  labs(x = "NDVI - Pixel 98", y = "Frequência Absoluta") +
  theme_light(base_size = 10)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```



```
# Box plot
ggplot(data = dados_2013_2021, aes(x = ndvi)) +
  geom_boxplot(color="blue", fill="lightcyan") +
  labs(x = "NDVI - Pixel 98") +
  theme_light(base_size = 10)
```




```
# Medidas descritivas dos dados
describe(dados_2013_2021[, -1])
```

```
##          vars    n   mean   sd median trimmed   mad    min    max range
## pixel*      1 206    1.00 0.00    1.00    1.00    0.00    1.00    1.00    0.0
## ndvi        2 206    0.57 0.18    0.63    0.58    0.18    0.23    0.83    0.6
## ano         3 206 2017.02 2.58 2017.00 2017.02    2.97 2013.00 2021.00    8.0
## mes         4 206    6.36 3.43    6.00    6.33    4.45    1.00   12.00   11.0
## dia         5 206   15.32 9.03   16.00   15.31  10.38    1.00   31.00   30.0
## ordem_ano*  6 206   11.95 6.62   12.00   11.95    8.90    1.00   23.00   22.0
##          skew kurtosis   se
## pixel*      NaN      NaN 0.00
## ndvi        -0.48   -1.26 0.01
## ano          0.00   -1.24 0.18
## mes          0.08   -1.18 0.24
## dia         -0.01   -1.14 0.63
## ordem_ano*  0.00   -1.22 0.46
```

Questão 2

```
# Transformando os dados em uma série
df <- ts(dados_2013_2021$ndvi, start = c(2013, 1), frequency = 23)
t <- time(df)
```

```
ggplot(data = dados_2013_2021, aes(x = data, ndvi)) +
  geom_line(color = "blue") +
  labs(x = "Ano", y = "NDVI - Pixel") +
  theme_light(base_size = 10)
```



>

Com base no gráfico ilustrativo, é possível afirmar que a série exibe sazonalidade, uma vez que ao longo do tempo apresenta um padrão de comportamento acompanhado por ruídos brancos. Dessa forma, acreditamos que a série não demonstra uma tendência clara. Para avaliar isso, serão conduzidos dois testes: um teste de Dikey-Fuller para verificar a estacionariedade e um teste de Mann-Kendall para identificar possíveis tendências.

```
adf_test <- adf.test(df)
```

```
## Valor-p do teste Dickey-Fuller Aumentado - ADF: 0.01 ,
```

```
## portanto, a série de tempo é estacionária. Pois há evidências significativas de que podemos aceitar a
```

```
# executar o teste de Mann-Kendall para verificar se há tendência na série
```

```
mk_test <- mk.test(df)
```

```
## Valor-p do teste Mann-Kendall: 0.8271331 ,
```

```
## portanto, a série de tempo não apresenta tendência, pois há evidências significativas de que não pode
```

Questão 3

```
# Fazendo modelagem temporal por médias móveis
```

```
ndvi_ma <- df
```


```
amostra <- 3
```

```
filter_coefs <- rep(1/(2*amostra + 1), 2*amostra + 1)
```

```
ndvi_maa <- stats::filter(ndvi_ma, filter_coefs, sides = 2, method = "conv")
```

```
plot(ndvi_ma, xlab = "Ano", ylab = "NDVI por Médias Móveis", main = "Série Temporal NDVI - Pixel 98")
lines(ndvi_maa, col = "red")
```

## Série Temporal NDVI – Pixel 98




```
# Modelagem temporal por LOWESS
df_lowess <- df
tempo <- time(df)

dt<-data.frame(tempo = as.numeric(tempo), df_lowess = as.numeric(df_lowess))
fit<-lowess(dt)

fit1<-lowess(dt,f=1/3)
fit2<-lowess(dt,f=1/10)


ts.plot(df_lowess)
lines(fit,col="red")
lines(fit1,col="blue")
lines(fit2,col="green")

legend(1994.5,12000,legend=c("f=default",
                             "f=1/3",
                             "f=1/5"),
       col=c("red","blue","green"),
       lty=c(1,1,1),
       cex=0.5)
```




```
# Modelagem temporal por polinomio
ndvi_poly <- lm(dados_2013_2021$ndvi ~ poly(df))

plot(dados_2013_2021$ndvi, ylab = "NDVI - Pixel 98", xlab = "Ano")
lines(predict(ndvi_poly), col = "red")
```



```
# Usando a função stl para obter a decomposição dos componentes de tendência, sazonalidade e ruído
ndvi_stl <- stl(df, s.window = "periodic")
plot(ndvi_stl)
```



Ao analisar os gráficos anteriores, é evidente que a técnica de média móvel e a modelagem por polinômio foram as mais eficazes na captura da suavização dos dados observados.